# Механизмы искусственного интеллекта

Е. А. Черкашин

ИДСТУ им. В. М. Матросова СО РАН

10 февраля 2025 г., Иркутск

# К определению понятия «Искусственный интеллект»

К ИИ относятся программы, реализующие задачи, решение которых потребовало бы от человека использования его когнитивных способностей, выполнения творческих функций<sup>1</sup>.

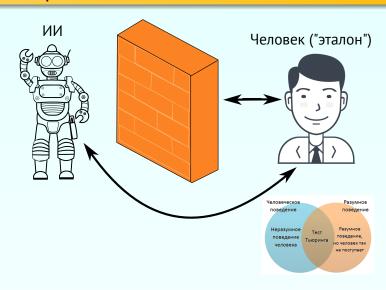
Определение из книги AIMA<sup>2</sup>:

	Рационально	Как человек
Рассуждать	0	0
Вести себя	0	0

<sup>&</sup>lt;sup>1</sup>Справочник ИИ, Т.1, 1990

<sup>&</sup>lt;sup>2</sup>P.Norvig, S.Russell. Artificial Intelligence Modern Approach

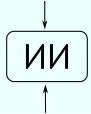
## Тест Тьюринга



Если Человек в процессе общения с ИИ будет думать, что общается с Человеком, то ИИ обладает требуемым свойством.

## ИИ как модель человека

Моделирование рассуждений → моделирование «математики»



Моделирование мозга → моделирование самоорганизующихся систем

## Свойства и классы задач ИИ

### Свойства задач

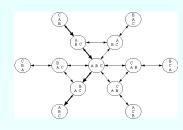
- Не существует алгоритма решения
- Обработка символьной информации
- Автоматизация принятия решения
- □ Решение комбинация «возможностей»
- Обработка неполной и противоречивой информации

### Классы задач

- 1. Игры
- 2. Автоматическое доказательство теорем
- 3. Восприятие и распознавание образов
- 4. Планирование действий (Problem Solving)
- 5. Понимание естественного языка, перевод
- 6. Логическое программирование
- 7. Экспертные системы
- 8. Интеллектные и аналитические информационные системы
- 9. Восприятие и усвоение знаний (Machine learning)
- Интеллектное управление [производством] ...
- 11. Робототехника (Robotics)
- 12. Системы поддержки принятия решений

# Планирование действий (Problem Solving)





**Формализация** (SSG, State Space Graph)

- □ Структура данных для представления состояния
- $extstyle extstyle \Phi$ ормализация **правил перехода** из состояния в состояние G
- $lue{}$  Программирование **распознавателя** *целевого состояния* R(v)
- $\square$  Задание **исходного состояния** I

$$SSG = < G, R(v), I >, G = < V, E >, v \in V.$$

## Представление знаний

Естественно определить данные как некоторые сведения об отдельных объектах, а знания – о мире в целом.

**Данные** представляют информацию о существовании объектов, представляемых значениями признаков, а **знания** – информацию о существующих в мире закономерных связях между признаками и запрещающих некоторые другие сочетания свойств у объектов.

**Данные** – это информация о существовании объектов с некоторым набором свойств, **знания** – информация о **не**существовании объектов с некоторым набором свойств.

Пусть  $H(x) \Leftrightarrow «x$  является человеком», а M(x) – «x – смертен».

«сократ, s, является человеком»:

$$A_1 = H(s),$$

«не существует бессмертных людей»):

$$A_2 = \neg \exists x \big( H(x) \& \neg M(x) \big),$$

преобразуем во «все люди смертны»:

$$A_3 = \forall x \big( H(x) \to M(x) \big).$$

...все объекты x, обладающие свойством H, будут обладать свойством M.

# Обработка информации «в математике»

Добавим информатики. Утверждение «Сократ – человек» представим как H(s), где s – это Сократ. Теперь из **знания**  $A_3$  и **исходного данного** H(s) получим новую информацию о Сократе:

$$B = \left(H(s)\& \overbrace{\forall x \big(H(x) \to M(x)\big)}^{A_3}\right) \to M(s).$$

Из того, что Сократ – человек и что все люди смертны, следует, что Сократ тоже смертен M(s). Доказательство «от противного»:

- 1. Требуется опровергнуть высказывание  $\neg B = \mathsf{True}$
- 2.  $B = \operatorname{False} \vdash H(s) \& A_3 = \operatorname{True}, M(s) = \operatorname{False}$
- 3.  $H(s)\&A_3=\operatorname{True}\vdash H(s)=\operatorname{True}, \frac{A_3}{}=\operatorname{True}$
- 4. Подставим s вместо x в  $A_3$ , получим  $H(s) \to M(s)$
- 5.  $H(s) = \mathsf{True}, M(s) = \mathsf{False} \vdash H(s) \to M(s) = \mathsf{False}$
- 6.  $H(s) \rightarrow M(s) = \text{False} \vdash A_3 = \text{False}$
- 7. Из п. 3 следует  $A_3 = \text{True}$ , а из п. 6  $A_3 = \text{False}$
- 8. В формальной (математической) логике в п. 7 получено противоречие
- 9. Следовательно,  $\neg B \neq \mathsf{False}, B = \mathsf{True}$
- 10. Из п. 9 следует  $M(s) = \text{True } \square$  (ЧТД, QED<sup>3</sup>)

 $<sup>^3</sup>$  Quod Erat Demonstrandum, «что и требовалось показать», "which was to be demonstrated"

## Логическое программирование

### Сократим доказательство

Будем выписывать только истинные высказывания, т.е.

$$M(s)\Leftrightarrow M(s)=$$
 True («Сократ смертен»),  $\neg M(s)\Leftrightarrow M(s)=$  False («Сократ бессмертен»)

$$B = \left(H(s) \& \overbrace{\forall x \big(H(x) \to M(x)\big)}^{A_3}\right) \to M(s).$$

- 1. Опровергаем  $\neg B$
- 2.  $B \vdash H(s) \& A_3, M(s)$
- 3.  $H(s)\&A_3 \vdash H(s), A_3$
- 4.  $A_3\{s/x\}=H(s) \rightarrow M(s)$
- 5.  $H(s), \neg M(s) \vdash \neg (H(s) \rightarrow M(s))$
- 6.  $\neg(H(s) \rightarrow M(s)) \vdash \neg A_3$
- 7. Из п. 3 следует  $A_3$ , а из п. 6  $\neg A_3$
- 8. В п. **7** получено **противоречие**
- 9. Следовательно, B
- 10. Из п. 9 M(s)  $\square$

### Программа (теория)

$$h(s)$$
.  $m(X) := h(X)$ . %  $h(X) -> m(X)$ .

#### Консультация

?- [socrates]. % Загрузка теории из файла true.

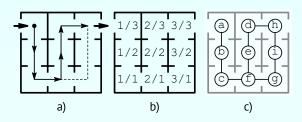
?- m(s). % Запрос true.

#### Объяснение вывода

?- trace. true.

Exit: (10) m(s) ? % следовательно m(s).

# Планирование действий



### Теория лабиринта

```
e(a,b). e(b,c). e(c,f).
e(f,e). e(e,d). e(d,h).
e(f,g). e(g,i). e(i,h).
% "Знания"
% Что такое "путь".
```

path(A,B) :- e(A,B).
path(A,B) :- e(A,C), path(C,B).

0

# **Запрос** ?- path(a,h).

% "Данные"

true ; true ; false.

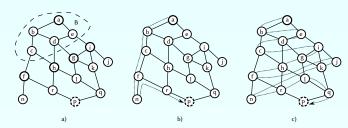
## Конструктивное решение

path(A,B, [A-B]) :- e(A,B).
path(A,B, [A-C|T]) :- e(A,C), path(C,B,T).

### Запрос

?- path(a,h,L). L = [a-b, b-c, c-f, f-e, e-d, d-h]; L = [a-b, b-c, c-f, f-g, g-i, i-h]; false.

## Стратегии поиск в SSG



### Поиск в глубину

```
dfs(V,[]):- r(V).
dfs(V,[V-N]T]):- \ \ r(V), after(V,N), dfs(N,T).
r(h).
after(X,Y):- e(X,Y); e(Y,X).
?- dfs(a. S).
S = [a-b, b-c, c-f, f-e, e-d, d-h];
S = [a-b, b-c, c-f, f-e, e-d, d-e, e-d, d-h];
```

S = [a-b, b-c, c-f, f-e, e-d, d-e, e-d, d-e, ...]

## Поиск в ширину

```
bfs([[X|T]|_],[X|T]):-r(X),!.
                               % (1)
bfs([[X|T]|Ways], S):-
   findall([Y,X|T],
                                % (2)
     (after(X,Y), \ member(Y,[X|T])),
   L),
   append(Ways, L, NWays),
                               % (3)
   bfs(NWays, S).
?- bfs([[a]].S).
S = [h, d, e, f, c, b, a].
```

## Использование дополнительной информации

Зададим функцию  $f\!\!: V \to R$  следующего вида:

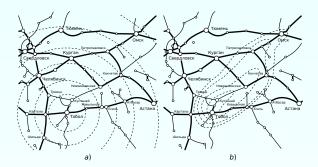
$$f(x) = g(x) + r(x) \\$$

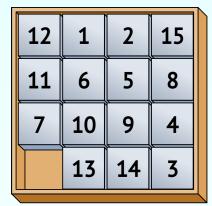
– стоимость кратчайшего пути (КП) через  $x,\,g(x)$  – до  $x,\,r(x)$  – КП до целевой вершины (не известен).

Оценка r(x) снизу –  $h(x), h(x) \leqslant r(x)$ . Теперь

$$f(x) \leqslant g(x) + h(x)$$
.

bf1([\_-s(G,[Target|T]) |\_],% (1) Target-\_,s(G,[Target|T])):-!.
bf1([\_-s(G,[X|T])|Ways], Target-GPS, S):-Target\=X, findall(F1-s(G1,[Y,X|T]), after([X|T],G,GPS, Y,G1,F1), L), append(L, Ways, NWays), keysort(NWays, SNWays), bf1(SNWays, Target-GPS, S). after([S|R],SG, GPS, T,TG, F):transdist(S.T.D), % \+ member(T.[S|R]). TG is SG + D, geodist(T, GPS, GDist), % (2) F is TG + GDist. bf(Start, Target, Sol):geocode(Target, Lon, Lat, \_), bf1([0-s(0,[Start])], Target-ll(Lon,Lat), Sol). % (3)





# Поиск решения с использованием эвристики

```
center% ./15-solve 100 20 1
Environment:
USE HEURISTIC=1
Puzzle 15 solving program
State(00.00[00])
<---solution--->
ø Step -----
5 1 3 4
9 2 6 8
13 10 15 0
14 12 7 11
x=2, y=3
State(00.16[16])
17 Step ---
  2 3 4
 9 10 11 12
13 14 15 0
x=3, y=3
State(17,00[17])
Tested 111 states.
```

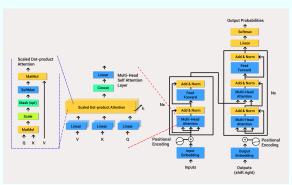
## Без эвристики

## Chat GPT 4

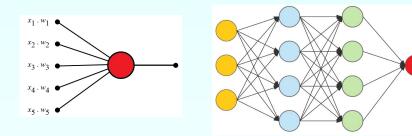
ChatGPT (Generative Pretrained Transformer, Порождающий [пред]треннированный преобразователь) – чат-бот OpenAI, запущенный в ноябре 2022.

...настроен при помощи обучения «с учителем» и «с подкреплением». Именно обучение с подкреплением делает ChatGPT **уникальным**.

...предназначен для реагирования на входные данные, представленные на естественном языке.



# Нейронные сети





## Анализ входного текста

GPT-3 Codex

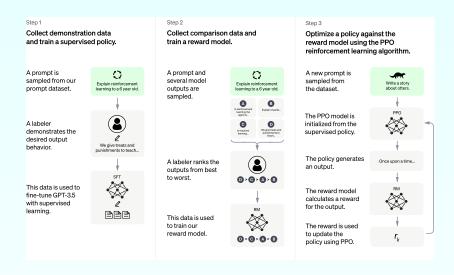
GPT-3 (Generative Pre-trained Transformer 3) uses a process called <u>tokenization</u> to break down text. Many words map to single tokens, though longer or more complex words often break down into multiple tokens. On average, tokens are roughly 4 characters long.

Clear Show example

Tokens Characters 56 258

GPT-3 (Generative Pre-trained Transformer 3) uses a process called token ization to break down text. Many words map to single tokens, though longer or more complex words often break down into multiple tokens. On average, tokens are roughly 4 characters long.

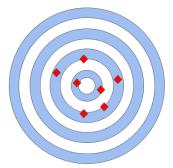
## Воспитание нейронной сети



# Цель воспитания



High capability Low alignment



Low capability High alignment